

CI209 - Inteligência Artificial




Prof. Aurora Pozo
DInf - UFPR

Especificação do segundo trabalho prático da disciplina ¹

Trabalho prático 2

Exemplo de dígito par



Exemplo de dígito ímpar



Figura 1: Exemplo de duas das imagens da base de dados MNIST utilizada neste trabalho.

Este trabalho é composto por duas partes:

- Implementar o algoritmo de treinamento do modelo Perceptron
- Comparar a sua implementação com o modelo de classificação *Multilayer Perceptron* implementado na biblioteca *scikit-learn*²

Você deverá baixar o código-base do trabalho e alterar dois arquivos: *my_perceptron.py* e *ml.py*

Ao final do trabalho, você deverá entender o conceito básico do funcionamento do perceptron e algumas de suas características em problemas de classificação.

Você poderá verificar o resultado da sua implementação utilizando os seguintes comandos:

```
$ python3 app_perceptron.py  
$ python3 ml.py
```

¹Elaborado por Bruno Henrique Meyer e Augusto Lopez Dantas (Prática em docência de Informática)

²<https://scikit-learn.org/>

Divisão do trabalho

Parte 1 Implementação do perceptron

Implemente a função *run_perceptron* no arquivo *my_perceptron.py*. A função será utilizada para atualizar os pesos do perceptron em cada época da execução do treinamento do modelo. Nos exemplos desse trabalho serão considerados apenas problemas de classificação binária, onde há apenas duas classes.

Os parâmetros aceitos pela função são:

- *weights*: lista que contém os pesos do perceptron. O **primeiro elemento** do vetor representa o **bias**.
- *data*: Matriz do tipo numpy array. Cada linha representa uma instância (ponto) com 1+N valores, onde N é a quantidade de atributos que serão fornecidos de entrada ao perceptron. O **primeiro elemento** de cada instância será **sempre 1.0** e serve para multiplicar pelo bias, o que simplifica a implementação das operações necessárias.
- *labels*: Vetor de tamanho N que contém o rótulo (0 ou 1) de cada instância. Os índices são relacionados aos índices das instâncias contidas no parâmetro *data*.
- *learning_rate*: Valor que deve ser multiplicado pelo tamanho do “passo” relacionado à atualização dos pesos

A função deverá retornar o vetor de pesos atualizado e a quantidade de erros (instâncias classificadas incorretamente) da época.

Para verificar o funcionamento de sua implementação, execute o comando:

```
$ python3 app_perceptron.py
```

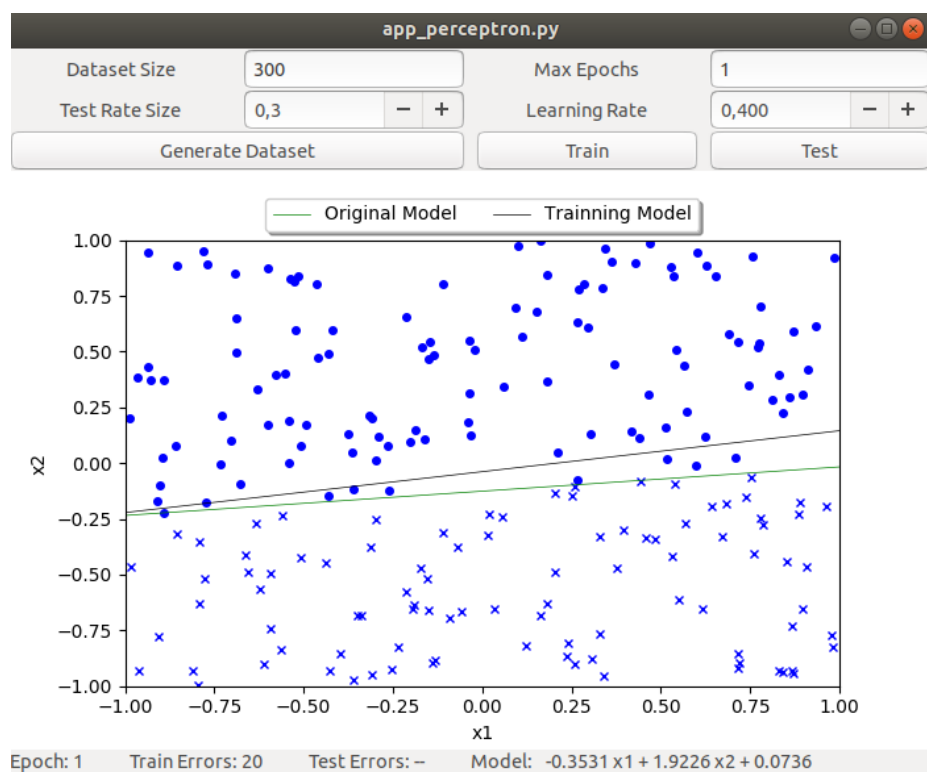


Figura 2: Visualização da execução do *app_perceptron.py*

Na Figura 2 é mostrada a interface para testar o perceptron. Você pode modificar os diferentes parâmetros e selecionar a opção “Train” para iniciar o processo de treinamento do modelo.

A linha verde representa a reta utilizada para gerar a distribuição dos pontos divididos em duas classes. O objetivo do perceptron é encontrar um conjunto de pesos e bias, representado pela linha preta, que seja o mais próximo possível da linha verde.

Parte 2 Classificação

O arquivo *ml.py* contém um código que carrega duas diferentes bases de classificação. Você deverá utilizar a biblioteca *scikit-learn* para verificar a acurácia do MLP³ (*Multilayer Perceptron*) nas duas bases de dados.

Você deverá usar o MLP com diferentes parâmetros, como o número de camadas, usando valores diferentes dos padrões da biblioteca. No relatório você pode comentar se esses parâmetros tiveram impacto na acurácia do classificador. Para mudar o número de camadas e neurônios por camada, você deverá especificar o parâmetro *hidden_layer_sizes*. A linha de código a seguir exemplifica como instanciar o MLP usando 2 camadas ocultas (50 na primeira e 100 na segunda). Para mais detalhes, consulte a [documentação original da biblioteca](#).

```
model = MLPClassifier(hidden_layer_sizes=(50,100))
```

As bases de dados são divididas na proporção de 3/4 para treinamento e 1/4 para teste. As bases de dados são:

- XOR: Dados artificiais de um problema clássico de classificação onde existem 4 agrupamentos de pontos divididos em 2 classes. A base contém duas características e 2000 instâncias.
- MNIST: Dados reais onde cada instância (ponto) representa uma imagem de um dígito. Cada imagem possui resolução de 28x28 (Figura 1), onde a intensidade de cada pixel é uma característica (784 no total). A base de dados foi reduzida em relação ao seu tamanho original e contém apenas 4000 instâncias. Os rótulos (classes) indicam se a imagem é de um dígito par ou ímpar.

No código disponibilizado já existe uma função que reduz as dimensões de cada base de dados para a visualização (de forma aproximada) dos datasets. A Figura 3 ilustra a distribuição das instâncias de cada base.

³https://scikit-learn.org/stable/modules/generated/sklearn.neural_network.MLPClassifier.html#sklearn.neural_network.MLPClassifier




Figura 3: Datasets

Você também deverá analisar um classificador linear que utiliza sua implementação do perceptron, que também será disponibilizado. Seu uso é semelhante aos algoritmos de classificação do *scikit-learn*, e contém os métodos *fit*, *predict* e *score*. O classificador está disponível no arquivo *ml.py* cujo nome do modelo é *PerceptronClassifier*. O modelo pode ser instanciado especificando as variáveis *learning_rate* (tamanho do “passo”) e *max_iter* (Número de iterações).

Ao final, seu programa deverá escrever na tela as acurácias nos conjuntos de teste obtidas em cada base de dados por cada modelo de classificação. A implementação do classificador que usa o seu Perceptron deverá apresentar uma acurácia de ao menos 80%.

Parte 3 Conclusões e Relatório

Crie um relatório de até 3 páginas reportando o desempenho dos classificadores sobre cada base de dados. O seu relatório também deverá tentar responder os seguintes questionamentos (você deverá explicar também a justificativa para a sua resposta):

- Na base de dados XOR, qual classificador teve melhor desempenho? Qual o motivo para isso acontecer?
- Quais as diferenças que você percebeu entre a base de dados XOR e MNIST? Como isso influencia na classificação?
- Quais parâmetros dos classificadores têm maior impacto no resultado?

Se preferir, utilize figuras, tabelas entre outros recursos. Recomenda-se o uso do L^AT_EX para construir o seu relatório.

Dicas

- Utilize a biblioteca `numpy`⁴ para facilitar as operações necessárias
- Consulte a documentação da biblioteca *scikit-learn* para verificar os exemplos de uso dos classificadores mencionados neste trabalho

Entrega

Você deverá entregar um arquivo compactado com o nome *login.tar.gz*, onde *login* é o nome do seu usuário no sistema do Departamento de Informática, que contenha os seguintes arquivos:

- *my_perceptron.py*
- *ml.py*
- *login.pdf*

Observações

Você deverá desenvolver e compreender todas implementações feitas no seu trabalho. Não serão admitidos quaisquer tipos de plágio.

⁴<https://numpy.org/>

Dúvidas

Dúvidas poderão ser retiradas por e-mail:

bhmeyer@inf.ufpr.br

aldantas@inf.ufpr.br